Taller 2 grupal

Caso de estudio.

Camilo Andrés Ortiz, Juan Torres y Juliana Rubio

Juan Carlos García

Estudiantes de Ciencia de datos

Departamento de Ingeniería Industrial

Pontificia Universidad Javeriana, Bogotá, Colombia

GUIA TALLERES ANALÍTICA I BASADOS EN CRISP-DM

BUSINESS UNDERSTANDING

Determine Business objectives

Background: Se espera de esta sección una valoración estratégica del entorno y de la compañía utilizando los siguientes marcos de referencia: para el análisis externo, PESTLE (documento PESTLE Analysis) y Fuerzas de Porter; para la combinación de análisis interno y externo, SWOT (KOTLER, pp 71).

PESTLE

1. **Político**: Evaluar políticas gubernamentales sobre protección de datos y ciberseguridad, especialmente con el crecimiento en la regulación de datos personales.

2. **Económico**: Analizar el impacto de la economía global en la inversión en tecnologías de análisis de datos, incluyendo tasas de interés y presupuestos en TI de compañías.

3. **Social**: Considerar la aceptación y confianza de los consumidores en el uso de datos personales, ya que una mayor aceptación puede facilitar la recolección y análisis de datos.

4. **Tecnológico**: Revisar avances en inteligencia artificial y machine learning, dado que estas tecnologías impactan directamente la capacidad de innovación y efectividad en el análisis de datos.

5. **Legal**: Identificar requisitos legales y estándares internacionales de privacidad (como el GDPR en la UE) que puedan influir en el manejo y almacenamiento de datos.

6. **Ambiental**: Examinar el enfoque ambiental de la empresa, ya que las prácticas sostenibles pueden mejorar la percepción de marca y atraer clientes con responsabilidad social corporativa.

Fuerzas de Porter

1. **Competencia en la industria**: Evaluar la cantidad de competidores y su nivel de innovación, ya que el mercado de análisis de datos es altamente competitivo y requiere una propuesta de valor diferenciada.

2. **Amenaza de nuevos entrantes**: Analizar las barreras de entrada, especialmente las certificaciones de calidad de datos y los costos tecnológicos, que pueden limitar la entrada de nuevos competidores.

3. **Poder de negociación de los proveedores**: Considerar el impacto de los proveedores de tecnología y servicios de datos, ya que pueden influir en los costos y la disponibilidad de herramientas y plataformas de análisis.

4. **Poder de negociación de los clientes**: Tener en cuenta el poder de los clientes (empresas u organizaciones) que buscan servicios de análisis de datos personalizados y que pueden cambiar de proveedor fácilmente si encuentran mejores servicios.

5. **Amenaza de productos sustitutos**: Analizar la posibilidad de que los clientes adopten alternativas, como plataformas de análisis interno, en lugar de contratar servicios externos de análisis de datos.

Análisis Interno y Externo (SWOT)

Fortalezas

- Capacidad técnica avanzada y experiencia en análisis de datos.
- Acceso a un equipo con experiencia en machine learning y big data.

Oportunidades

- Creciente demanda de análisis de datos en todos los sectores industriales.
- Expansión de la infraestructura de datos en la nube, lo cual permite mayor escalabilidad.

Debilidades

- Falta de reconocimiento de marca en un mercado muy competitivo.
- Alta dependencia de ciertos proveedores de tecnología.

Amenazas

- Cambios regulatorios que podrían afectar la recopilación y el procesamiento de datos.
- Alta competitividad y rápido avance tecnológico que requiere constante actualización de habilidades y herramientas.

Business goal: Establecimiento de el o los objetivos para el negocio del análisis de datos (mínimo 1, máximo 3) cada uno en una frase. Ver KOTLER, p.74

- Incrementar la cuota de mercado en servicios de análisis de datos para empresas medianas y grandes.
- Mejorar la precisión y la velocidad en la entrega de insights clave a los clientes mediante la implementación de tecnologías avanzadas de machine learning.
- Aumentar la satisfacción del cliente al ofrecer soluciones personalizadas de análisis de datos que respondan a sus necesidades específicas.

Business success criteria: Establecimiento del indicador clave (KPI) asociado a cada objetivo de negocio (mínimo 1, máximo 2 por objetivo).

Determine Data mining goals

Data mining goal: Establecer el o los objetivos del análisis de datos, lo que puede incluir especificaciones técnicas, (minimo1, máximo 3) cada uno en una frase.

- Incrementar la cuota de mercado en servicios de análisis de datos para empresas medianas y grandes.
- Mejorar la precisión y la velocidad en la entrega de insights clave a los clientes mediante la implementación de tecnologías avanzadas de machine learning.

Data mining success criteria: Establecimiento del indicador clave asociado a cada objetivo de minería (mínimo 1, máximo 2 por objetivo)

Objetivo 1: Incrementar la cuota de mercado en servicios de análisis de datos para empresas medianas y grandes.

- **KPI 1**: Crecimiento porcentual en la cuota de mercado en el segmento de empresas medianas y grandes (medido anualmente).

Objetivo 2: Mejorar la precisión y la velocidad en la entrega de insights clave a los clientes.

- **KPI 1**: Reducción del tiempo promedio de entrega de reportes y análisis (medido en días).

DATA UNDERSTANDING

Describe data: Descripción general de las bases de datos debe incluir: tamaño de la base de datos (registros/columnas), tipos de variables y significado básico de la variable (en ocasiones es posible describir un grupo de variables - utilice esas opciones para reducir/resumir su descripción).

Tamaño: Esta base contiene una muestra de 8.243 clientes

Número de Registros: Los registros representan cada cliente de la muestra.

Número de Columnas: 10 columnas.

Variables:

- **id**: Identificador único del cliente (variable numérica anónima sin significado adicional).
- **Fecha de nacimiento**: Fecha de nacimiento del cliente, formato dd/mm/yyyy, utilizada para calcular la edad del cliente (tipo de dato: fecha).
- **tipo cliente**: Indica el tipo de cliente: 1 para hombre, 2 para mujer, y 3 para cliente empresarial (variable categórica).
- **Factura online**: Variable binaria (0 o 1) que indica si el cliente recibe su factura únicamente de forma digital.
- **Antiguedad equipo**: Número de meses de antigüedad del equipo que el cliente posee (variable numérica continua).
- **Plan de datos**: Variable binaria (1 para plan premium de datos; 0 si no tiene plan premium).
- **Facturación**: Monto total facturado en los últimos seis meses, en la moneda local (variable numérica continua).
- **Mora**: Total de días de mora acumulados por el cliente en los últimos seis meses (variable numérica).
- **Fecha inicio contrato**: Fecha de inicio del primer contrato pospago del cliente (tipo de dato: fecha).

- **minutos**: Cantidad de minutos consumidos en los últimos seis meses (variable numérica continua).
- **resultado**: Variable objetivo, que indica si el cliente entró en churn (1 significa que hubo deserción; 0 indica que no)

<u>Explore data:</u> Incluye análisis descriptivos univariados y multivariados ***<u>relevantes</u>*** (no es necesario incluir todos los gráficos o tablas producidos) para responder las 3 preguntas fundamentales y los 2 objetivos del análisis descriptivo, atendiendo a las características claves del análisis (rapidez, precisión, confianza). Debe especificarse si se hizo sobre la base de datos entera o sobre una partición de la misma.

En primer lugar, se realizaron estadísticas descriptivas básicas, para entender como se comportaban nuestros datos

```
 Fecha de nacimiento                tipo cliente Factura online
 Min.   :1940-09-10 08:22:07.654   1:3740       0:4211
 1st Qu.:1955-01-16 17:56:56.843   2:3605       1:4032
 Median :1958-03-25 11:21:40.669   3: 898
 Mean   :1958-04-08 05:07:49.822
 3rd Qu.:1961-05-01 21:38:50.064
 Max.   :1992-12-05 04:14:37.111
 Antigüedad Equipo Plan de datos  facturación           mora
 Min.   : 1.00     0:1310        Min.   :-112588   Min.   :  0.00
 1st Qu.: 9.00     1:6933        1st Qu.: 203363   1st Qu.:  0.00
 Median :24.00                   Median : 268063   Median :  6.00
 Mean   :24.27                   Mean   : 267766   Mean   : 18.13
 3rd Qu.:39.00                   3rd Qu.: 333272   3rd Qu.: 35.00
 Max.   :48.00                   Max.   : 626111   Max.   :118.00
 Fecha inicio contrato              minutos      resultado
 Min.   :2011-12-13 07:49:29.13   Min.   :  100   0:6882
 1st Qu.:2016-06-14 08:32:32.54   1st Qu.:  708   1:1361
 Median :2017-03-04 16:27:59.85   Median : 1103
 Mean   :2017-01-01 23:38:29.68   Mean   : 1184
 3rd Qu.:2017-09-18 21:46:23.70   3rd Qu.: 1498
 Max.   :2019-01-03 07:52:55.11   Max.   :14103
```

Luego revisamos la distribución de las variables

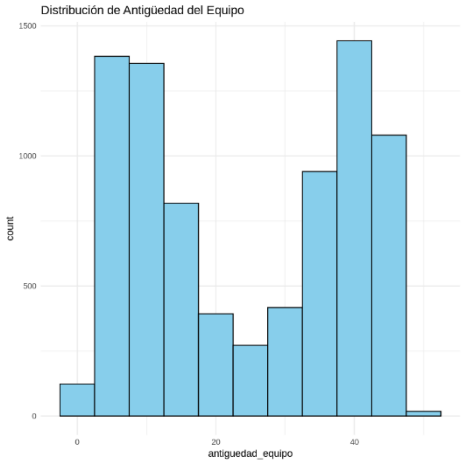
Distribución de Antigüedad del Equipo
count
antiguedad_equipo
0
500
1000
1500
0
20
40

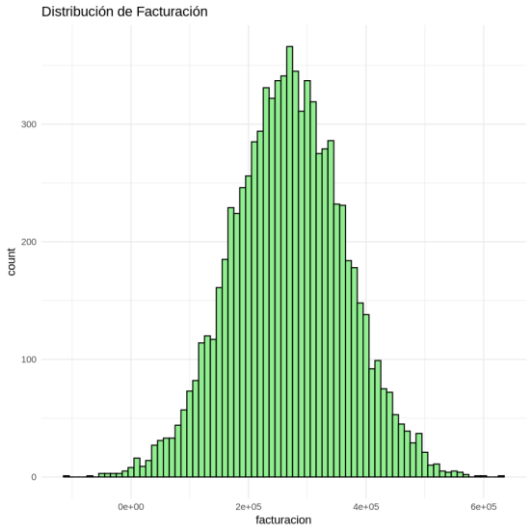
Distribución de Facturación
count
facturacion
0
100
200
300
0e+00
2e+05
4e+05
6e+05

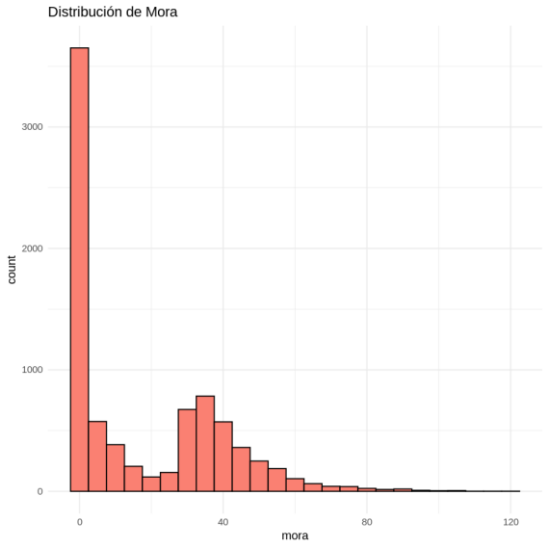
Distribución de Mora
count
mora
0
1000
2000
3000
0
40
80
120

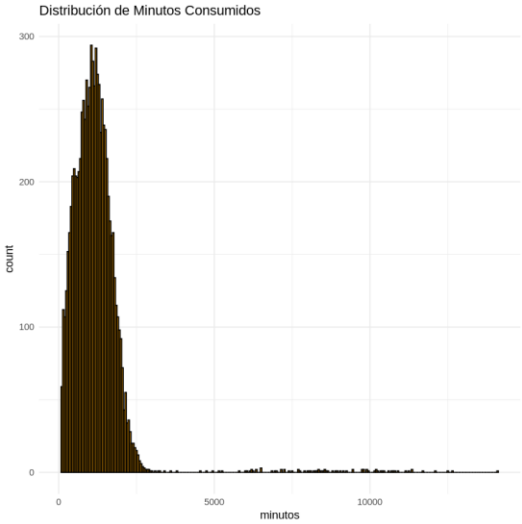
Distribución de Minutos Consumidos
count
minutos
0
100
200
300
0
5000
10000

Verify Data Quality: Informar de posibles datos atípicos (tanto posibles como imposibles) y perdidos en las variables, con potenciales explicaciones sobre su aparición.

1. **Antigüedad del Equipo (antiguedad)**
    - **Atípicos**: Pocos valores ligeramente fuera del rango, posiblemente equipos muy nuevos o antiguos.
    - **Conclusión**: Atípicos leves, no requieren intervención.
2. **Facturación (facturacion)**
    - **Atípicos**: Valores altos fuera del rango, potencialmente clientes con consumo alto o errores de facturación.
    - **Conclusión**: Revisar si estos valores extremos son válidos o errores.
3. **Mora (mora)**
    - **Atípicos**: Valores elevados (>100 días), posiblemente clientes con dificultades de pago.
    - **Conclusión**: Analizar estos casos para confirmar si son válidos o errores.
4. **Minutos Consumidos (minutos)**
    - **Atípicos**: Muchos valores altos (hasta 14,000 minutos), posiblemente clientes intensivos o errores de registro.
    - **Conclusión**: Verificar si representan consumo legítimo o problemas en los datos.

Datos Perdidos

- No observados visualmente; es necesario verificar programáticamente y tratarlos si se encuentran.

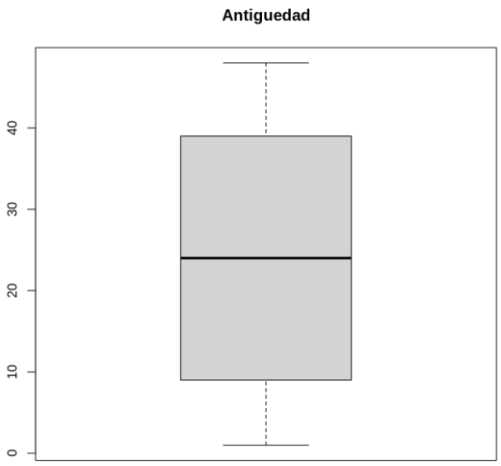

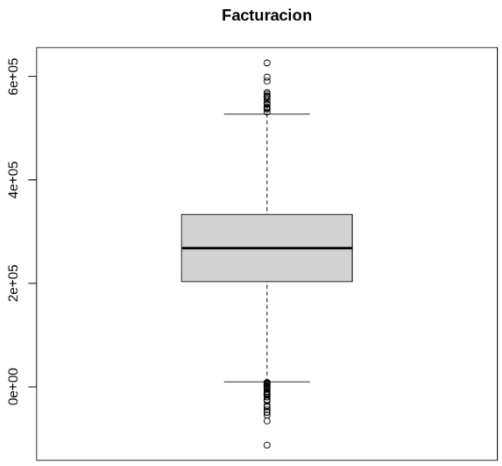

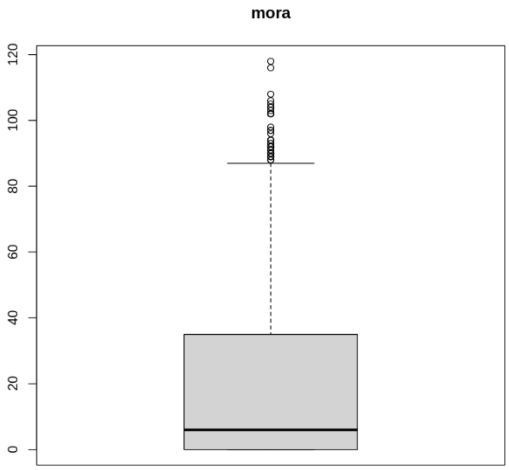

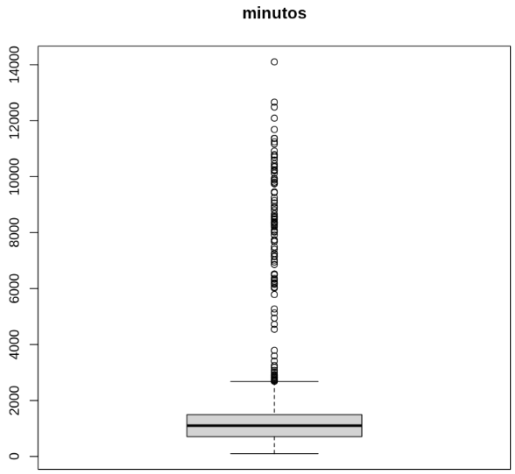

DATA PREPARATION

<u>Clean data:</u> Describir con trazabilidad y justificación los procesos de limpieza de datos realizados (remover, reemplazar, mantener, estudiar) que surgen del apartado *verify data quality* o especificar que no se realizó ningún proceso (basado, de nuevo, en *verify data quality*).

Conversión de Fechas de Nacimiento y Contrato

- **Proceso**: Se transformó el formato de las fechas en las variables Fecha de nacimiento y Fecha inicio contrato a tipo POSIXct, lo cual facilita el manejo de datos temporales y su transformación a años.

- **Justificación**: Convertir las fechas a un formato estándar facilita cálculos como la edad del cliente y el tiempo con el operador, necesarias para el análisis.

Creación de Variables Derivadas de Fechas

- **Proceso**: Se crearon dos nuevas variables, años_cliente y tiempo_contrato, al restar el año actual (2024) menos el año de nacimiento y el año de inicio del contrato, respectivamente.
- **Justificación**: Estas nuevas variables permiten interpretar la antigüedad del cliente y el tiempo de relación con el operador, factores que pueden influir en el análisis de churn.

Eliminación de Variables Irrelevantes

- **Proceso**: Se eliminaron las columnas id y Fecha de nacimiento, ya que id es únicamente un identificador y Fecha de nacimiento ya fue transformada en la variable años_cliente.
- **Justificación**: Estas columnas no aportan valor al modelo final y la eliminación reduce la complejidad del dataset.

Conversión de Variables Categóricas

- **Proceso**: Se convirtieron las variables tipo cliente, Factura online, y Plan de datos a factores, con niveles específicos (1, 2, 3 para tipo cliente y 0, 1 para las otras dos).
- **Justificación**: Al ser datos categóricos, la transformación a factores permite un análisis y modelado más efectivo en R.

Construct data: Describir con trazabilidad y justificación los procesos de transformación de variables o creación de nuevas variables *(feature engineering)* que se hayan realizado para crear la base de datos final.

Renombramiento de Variables

- **Proceso**: Se renombraron variables como tipo_cliente, Factura_online, Plan_de_datos, facturación y antiguedad_equipo para estandarizar los nombres y evitar problemas de compatibilidad en el análisis.
- **Justificación**: Estandarizar los nombres facilita la legibilidad y uso del dataset en el análisis.

Creación de Edad y Antigüedad del Cliente

- **Proceso**: Se crearon las variables años_cliente y tiempo_contrato usando las fechas de nacimiento y de inicio del contrato.
- **Justificación**: Estas variables proporcionan una medida del tiempo de relación con el operador, un posible predictor de churn.

Dataset description: Igual que en describe data, pero con el dataset limpio construido final en formato *tidy dataset*

Variables en el Dataset Limpio y Construido

1. **tipo_cliente**: Factor que indica el tipo de cliente (1: Hombre, 2: Mujer, 3: Cliente empresarial).
2. **Factura_online**: Factor binario que indica si el cliente recibe únicamente su factura online (0 o 1).
3. **Plan_de_datos**: Factor binario que indica si el cliente tiene un plan premium (0 o 1).
4. **facturación**: Total facturación en los últimos seis meses (numérica).
5. **mora**: Total de días de mora acumulados por el cliente (numérica).
6. **antiguedad_equipo**: Meses de antigüedad del equipo (numérica).
7. **minutos**: Total de minutos consumidos en los últimos seis meses (numérica).
8. **años_cliente**: Años que el cliente ha tenido relación con el operador (numérica).
9. **tiempo_contrato**: Tiempo en años desde el inicio del primer contrato (numérica).
10. **resultado**: Variable objetivo, donde 0 indica que no hubo deserción y 1 indica que sí (binaria).

MODELING & EVALUATION

Select modeling techniques: Especificar la o las técnicas que se utilizarán para el modelado de datos, y mostrar en qué medida se cumplen o no los supuestos y racionales para utilizar dichas técnicas.

Técnicas Utilizadas: Se usaron **Random Forest, Boosting y Stacking** debido a su capacidad para manejar datos desbalanceados y su habilidad para captar relaciones no lineales.

Cumplimiento de Supuestos: Estas técnicas no requieren suposiciones estrictas de normalidad o linealidad, lo cual es adecuado dada la naturaleza de los datos. Además, la clasificación binaria es compatible con ambas técnicas, y se usó el ajuste de pesos para tratar el desbalance de clase

Generate test design: Incluye lo que aplique entre: mecanismos de comparación de técnicas, variaciones de las técnicas que se compararán, preparación de bases de entrenamiento, validación y/o prueba, mecanismos de control del sobreajuste o subajuste *(overfitting/underfitting)*, mecanismos de selección de variables (*feature selection*). Puede incluir elementos adicionales del diseño de pruebas que se realizará para los modelos.

Mecanismos de Comparación: Se usaron métricas de rendimiento como AUC-ROC, precisión, recall, y F1-score para comparar los modelos.

Preparación de Conjuntos de Datos: Se realizó una división 80-20 entre los datos de entrenamiento y prueba. Se aplicaron técnicas de validación cruzada para evaluar el rendimiento y prevenir el sobreajuste.

Control de Sobreajuste/Subajuste: Ajustes de hiperparámetros mediante búsqueda en cuadrícula (Grid Search) para minimizar el riesgo de sobreajuste y mejorar la generalización.

Selección de Variables: Se usó la importancia de características (feature importance) en Random Forest para identificar las variables más relevantes

Build model: Incluye lo que aplique entre: parametrización y selección de la parametrización final utilizada para cada modelo o variante de modelo a utilizar, mecanismos de selección de hiperparámetros.

Parametrización:

- **Random Forest**: Ajuste de n_estimators (número de árboles) y max_depth.
- **Selección de Hiperparámetros**: Grid Search se empleó para seleccionar los hiperparámetros más óptimos en base a la validación cruzada.

Assess model: Incluye todos los reportes que permitan valorar los resultados de los modelos y compararlos entre sí y contra los objetivos de minería, incluyendo desempeño, robustez y calidad general del modelo. Termina con la selección del modelo o modelos finales de análisis de modo que cumplan los objetivos de minería y apoyen la consecución de los objetivos de negocio. Evidenciar impacto en métricas KPI definidas en un comienzo.

Evaluación de Desempeño:

- Se utilizó el conjunto de prueba para calcular métricas de desempeño.
- Se realizó un **stacking** con Random Forest y GBM, observando mejoras en el AUC.

Comparación y Selección del Modelo Final: Se eligió el modelo con mejor AUC-ROC y balance entre precisión y sensibilidad para cumplir con los objetivos de KPI.

DEPLOYMENT

Produce final report: este es un reporte gerencial que incluye:

- Definición de estrategia(s) sugerida(s) para lograr el/los objetivos de negocio (marco fundamental, 4ps actualizadas KOTLER p. 47 con foco en *programs*). Escoger máximo 3 estrategias por objetivo.
- Análisis costo/beneficio de las estrategias (como mínimo un mecanismo para evaluarlo o una simulación de potenciales objetivos y resultados; con foco en *performance* dentro del marco de las 4ps actualizadas KOTLER p. 47)
- Potenciales siguientes pasos de análisis necesarios.

Definición de Estrategias Sugeridas:

- Personalización de Planes: Crear planes de suscripción personalizados que se adapten a las necesidades de los clientes con mayor riesgo de abandono. Esto podría incluir opciones de precios más flexibles o características adicionales.

- Programa de Fidelización: Implementar un sistema de recompensas para clientes leales, con incentivos como descuentos, acceso exclusivo a servicios o beneficios adicionales, para aumentar su satisfacción y compromiso.

- Mejoras en Atención al Cliente: Fortalecer la calidad y velocidad de respuesta en el servicio al cliente, lo que incluye la capacitación continua de los agentes y la optimización de los canales de soporte, para resolver problemas rápidamente y reducir la insatisfacción.

Análisis Costo/Beneficio:

- Evaluación de Costos: Analizar los recursos necesarios para cada estrategia, como el costo de desarrollo de nuevos planes, el presupuesto para recompensas, y los gastos de capacitación y mejoras tecnológicas en el soporte.

- Simulación de Resultados Potenciales: Realizar una simulación que estime el impacto de cada estrategia en la retención de clientes y en el incremento del valor de vida del cliente (Customer Lifetime Value, CLV) para entender el retorno de inversión (ROI) a lo largo del tiempo.

Potenciales Siguientes Pasos de Análisis:

- Monitoreo Continuo del Modelo: Implementar un sistema de seguimiento para evaluar continuamente el desempeño de los modelos de predicción y realizar ajustes según cambien las tendencias de los datos.

- Recopilación de Más Datos: Enfocar la recolección de datos adicionales, como la interacción en redes sociales o encuestas de satisfacción, para mejorar la precisión en la predicción del abandono.

- Evaluación de Nuevas Variables: Analizar otras posibles variables que podrían influir en la retención, como cambios en la competencia o situaciones económicas, para mejorar la efectividad de las estrategias a largo plazo.

Recomendaciones

1. No cambiar el encabezado de la presentación.
2. El tamaño de letra de todo gráfico debe ser igual al texto de los párrafos (al menos que se pueda leer).
3. Para la fase 1 (entorno del negocio), se recomienda la exploración de la página Euromonitor para la cual se adjunta una guía de registro en la misma.
4. Letra mínima de tamaño 10. Las gráficas deben ser visibles e inteligibles (si son pequeñas, al hacer zoom deben ser visibles). No se requiere incluir código, puede hacerlo solo si es absolutamente necesario para la trazabilidad, aunque se prefieren, en ese caso, ecuaciones.
5. Todas las fases se califican sobre 10 para un total de 50 en cada informe.